

PRZEWODNIK PRAKTYCZNY

Lakeflow Connect

Ingestia z Azure SQL Database przez zarządzany konektor SQL Server

Ten przewodnik ładuje bazę Azure SQL Database do Unity Catalog za pomocą zarządzanego konektora SQL Server w Lakeflow Connect. Konektor składa się z trzech obiektów. **Połączenie Unity Catalog** (connection) przechowuje adres i poświadczenia źródła. **Brama ingestii** (ingestion gateway) to pipeline na klasycznych zasobach, który działa w sposób ciągły: pobiera początkowy snapshot, a potem strumień zmian z bazy, i zapisuje dane w wolumenie Unity Catalog. **Zarządzany pipeline ingestii** działa na serverless i nanosi zapisane dane na streaming tables w schemacie docelowym.

Źródłem na tym szkoleniu jest przykładowa baza AdventureWorksLT, tworzona przez `infra/terraform` z repozytorium szkolenia i przygotowywana skryptami z `infra/sql/` (`create_login_master.sql`, `enable_cdc.sql`) oraz skryptem narzędziowym Databricks. Notebook demonstracyjny `02a_lakeflow_connect_demo` przechodzi przez te same kroki na zajęciach.

Przed rozpoczęciem potrzebujesz:

- subskrypcji Azure, w której możesz tworzyć zasoby, z rolami Contributor i User Access Administrator, a także Terraform 1.5 lub nowszego, Azure CLI i `sqlcmd` (albo Azure Data Studio)
- workspace'u Azure Databricks z włączonym Unity Catalog i zasobami serverless
- uprawnienia do tworzenia klastrów bez ograniczeń, bo brama działa na klasycznych zasobach
- w Unity Catalog: `CREATE CONNECTION` na metastore (albo `USE CONNECTION` na istniejącym połączeniu), `USE CATALOG` na katalogu docelowym oraz `USE SCHEMA`, `CREATE TABLE` i `CREATE VOLUME` na istniejących schematach lub `CREATE SCHEMA` na katalogu

Subskrypcja szkoleniowa jest współdzielona z innymi szkoleniami. Przed uruchomieniem `terraform apply` lub `terraform destroy` uzgodnij termin.

Krok	Zadanie
1	Utworzenie bazy źródłowej przez Terraform
2	Włączenie CDC i utworzenie użytkownika ingestii
3	Utworzenie połączenia Unity Catalog
4	Utworzenie bramy i pipeline'u ingestii
5	Sprawdzenie załadowanych tabel
6	Test przepływu zmian (CDC)
7	Kontrola kosztów i sprzątanie

KROK 1

Utworzenie bazy źródłowej przez Terraform

W `infra/terraform` skopiuj przykładowy plik zmiennych i uzupełnij go. Hasło administratora SQL ustaw przez zmienną środowiskową, a nie w pliku, i dodaj publiczny adres IP komputera, z którego uruchomisz `sqlcmd`.

```
cd infra/terraform
cp terraform.tfvars.example terraform.tfvars      # prefix, dates, trainer_ip_cidrs
export TF_VAR_sql_admin_password='<strong password>'
terraform init
terraform plan
terraform apply
```

Plik `sql_server.tf` tworzy dla Lakeflow Connect następujące zasoby:

Zasób	Ustawienie	Po co
<code>azurerm_mssql_server</code>	TLS 1.2, administrator deatrainier	Serwer logiczny, na którym działa baza
<code>azurerm_mssql_database</code>	<code>sku_name = "GP_S_Gen5_1", min_capacity = 0.5, auto_pause_delay_in_minutes = 15, sample_name = "AdventureWorksLT"</code>	General Purpose serverless do 1 vCore: najtańszy poziom obsługujący CDC; usypia się po 15 minutach bez aktywności
<code>azurerm_mssql_firewall_rule</code> <code>AllowAzureServices</code>	<code>0.0.0.0 do 0.0.0.0</code>	Pozwala bramie działającej w Azure połączyć się z serwerem
<code>azurerm_mssql_firewall_rule</code> <code>trainer-NN</code>	<code>Z trainer_ip_cidrs</code>	Pozwala połączyć się przez <code>sqlcmd</code> z własnego komputera

CDC w Azure SQL Database działa na każdym poziomie vCore, a w modelu DTU dopiero od S3, więc nie obniżaj SKU. Reguła *Allow Azure services* otwiera serwer dla dowolnego tenanta Azure i jest do przyjęcia tylko dla krótko żyjącej bazy szkoleniowej. Na produkcji użyj workspace'u we własnej sieci wirtualnej (VNet injection) z service endpoint lub private endpoint.

Po zakończeniu `apply` odczytaj wartości potrzebne w kolejnych krokach:

```
terraform output sql_server_fqdn          # sql-dea-training-
<suffix>.database.windows.net
terraform output sql_database_name        # AdventureWorksLT
terraform output lakeflow_connect_connection_summary # host, port 1433, database, user
```

KROK 2

Włączenie CDC i utworzenie użytkownika ingestii

Bazę przygotowują dwa skrypty, uruchamiane w tej kolejności:

- `infra/sql/create_login_master.sql`, uruchamiany na bazie **master**, tworzy login serwera `lakeflow_connect` i dodaje go do roli serwerowej `##MS_DatabaseConnector##`. W Azure SQL Database użytkownik konektora potrzebuje tej roli, żeby mieć dostęp do **master**, a role serwerowe przyjmują tylko loginy, więc sam użytkownik bazy (contained user) nie wystarczy.
- `infra/sql/enable_cdc.sql`, uruchamiany na bazie **AdventureWorksLT**, włącza CDC dla bazy i dla czterech tabel w schemacie `SalesLT`: `Customer`, `Product`, `SalesOrderHeader` i `SalesOrderDetail`. Mapuje login na użytkownika bazy i nadaje mu prawo odczytu tych tabel i schematu `cdc` oraz uprawnienia do metadanych z tabeli dla Azure SQL Database w dokumentacji konektora: `VIEW DATABASE STATE` i `SELECT` na 14 widokach

katalogowych `sys`. Uprawnienia `EXECUTE` na `sp_tables` i podobnych procedurach dotyczą innych wariantów SQL Server; w Azure SQL Database kończą się błędem 4629.

Oba skrypty sprawdzają, co już istnieje, więc można je bezpiecznie uruchamiać wielokrotnie. Przed uruchomieniem zastąp hasło zastępcze `CHANGE_ME-LakeflowC0nnect!` w `create_login_master.sql` własnym silnym hasłem. To samo hasło wpiszesz w połączeniu w kroku 3. Uruchom oba jako administrator SQL:

```
sqlcmd -S "$(terraform output -raw sql_server_fqdn)" -d master \
-U deatrainner -P "$TF_VAR_sql_admin_password" -i ../sql/create_login_master.sql
sqlcmd -S "$(terraform output -raw sql_server_fqdn)" -d AdventureWorksLT \
-U deatrainner -P "$TF_VAR_sql_admin_password" -i ../sql/enable_cdc.sql
```

Jeśli `create_login_master.sql` został już uruchomiony z hasłem zastępczym, zmień je na bazie `master`:

```
ALTER LOGIN lakeflow_connect WITH PASSWORD = N'<your password>';
```

Sprawdź wynik. Pierwsze zapytanie powinno zwrócić 1, a procedura powinna wypisać cztery instancje przechwytywania:

```
SELECT is_cdc_enabled FROM sys.databases WHERE name = DB_NAME();
EXEC sys.sp_cdc_help_change_data_capture;
```

Change tracking czy CDC

Konektor odczytuje zmiany przez change tracking albo change data capture w SQL Server. Jeśli dla tabeli włączone są oba mechanizmy, używa change tracking.

	Change tracking	Change data capture
Rejestruje	Fakt zmiany wiersza	Każdą operację, z obrazem przed i po
Wymaga	Klucza głównego	Klucz główny niepotrzebny
Obciążenie źródła	Niskie	Wyższe: czyta dziennik transakcji i zapisuje tabele zmian
Poziom Azure SQL	Dowolny	Poziomy vCore albo DTU od S3
Zalecenie Databricks	Tabele z kluczem głównym	Tabele bez klucza głównego

Cztery tabele `SalesLT` mają klucze główne, więc change tracking też by zadziałał. Na szkoleniu używamy CDC, żeby było widać tabele zmian w bazie. Wariant z change tracking jest zakomentowany na końcu `enable_cdc.sql`. Dla jednej tabeli włączaj tylko jeden mechanizm.

Dodatkowe uprawnienia

`enable_cdc.sql` nie tworzy obiektów śledzących zmiany schematu (DDL support objects), których wymaga ingestia przez CDC. Zainstaluj je skryptem narzędziowym Databricks przed krokiem 4: pobierz `utility_script.sql` ze strony dokumentacji konektora *Prepare SQL Server for ingestion using the utility objects script*, uruchom go jako administrator w `AdventureWorksLT`, a następnie wykonaj dwie poniższe procedury. `SELECT dbo.lakeflowDetectPlatform()` powinno zwrócić `AZURE_SQL_DATABASE`. Przycisk **Validate** w kreatorze w kroku 4 potwierdzi wynik.

```
EXEC dbo.lakeflowSetupChangeDataCapture @Tables = 'SCHEMAS:SalesLT', @User = 'lakeflow_connect';  
EXEC dbo.lakeflowFixPermissions          @Tables = 'SCHEMAS:SalesLT', @User = 'lakeflow_connect';
```

KROK 3

Utworzenie połączenia Unity Catalog

W workspace Databricks otwórz **Catalog**, potem **Connect** (w niektórych workspace'ach **External data**) i **Connections**, a następnie wybierz **Create connection**. Połączenie można też utworzyć w kreatorze ingestii w kroku 4.

Pole	Wartość
Connection name	retailhub_sqlserver
Connection type	SQL Server
Host	Wynik sql_server_fqdn, np. sql-dea-training-ab12c.database.windows.net
Port	1433
User	lakeflow_connect
Password	Hasło ustawione w kroku 2

Wybierz **Create connection**. Połączenie jest teraz obiektem zabezpieczanym Unity Catalog: osoby tworzące pipeline'y ingestii potrzebują na nim `USE CONNECTION`, ale nigdy nie widzą hasła.

```
SHOW CONNECTIONS;  
DESCRIBE CONNECTION retailhub_sqlserver;  
GRANT USE CONNECTION ON CONNECTION retailhub_sqlserver TO `data_engineers`;
```

KROK 4

Utworzenie bramy i pipeline'u ingestii

Na pasku bocznym workspace'u otwórz **Data Ingestion** i w sekcji **Databricks connectors** wybierz **SQL Server**. Kreator utworzy oba pipeline'y.

Strona kreatora	Ustawienie	Wartość na szkoleniu
Connection	Połączenie	retailhub_sqlserver
Ingestion setup	Nazwa pipeline'u ingestii	retailhub_sqlserver_ingestion
	Lokalizacja event logu	retailhub_trainer.lakeflow_staging
	Nazwa bramy ingestii	retailhub_sqlserver_gateway
	Staging location	Katalog retailhub_trainer, schemat lakeflow_staging; tu brama tworzy swój wolumen
Source	Tabele	AdventureWorksLT › SalesLT › Customer, Product, SalesOrderHeader, SalesOrderDetail
	History tracking	Wyłączone (SCD typu 1): wiersze docelowe są aktualizowane i usuwane tak jak w źródle
Destination	Katalog i schemat	retailhub_trainer.lakeflow_connect
Database setup	Validate	Przed przejściem dalej popraw wszystko, co zostanie zgłoszone (zob. krok 2)
Schedules and notifications	Harmonogram	Brak na potrzeby demo; na produkcji np. co 30 minut
	Powiadomienia	Twój e-mail przy błędzie

Wybierz **Save and run pipeline**. W **Jobs & Pipelines** zobaczysz dwa pipeline'y:

- **Brama** uruchamia klasyczne zasoby, zapisuje w wolumenie roboczym początkowy snapshot czterech tabel, a potem stale czyta strumień zmian. Jest przeznaczona do pracy ciągłej.
- **Pipeline ingestii** działa w trybie wyzwalanych aktualizacji na serverless. Każda aktualizacja nanosi zapisany snapshot i zmiany na docelowe streaming tables.

Pierwszy snapshot trwa kilka minut. Widok listy pipeline'u ingestii pokazuje, ile rekordów przetworzono dla każdej tabeli; kolumny *Upserted records* i *Deleted records* można dodać w ustawieniach kolumn. Jeden pipeline obsługuje do 250 tabel, a każdy pipeline ingestii ma dokładnie jedną bramę.

Nadaj uczestnikom szkolenia prawo odczytu miejsca docelowego:

```
GRANT USE CATALOG ON CATALOG retailhub_trainer TO `dea-training`;  
GRANT USE SCHEMA, SELECT ON SCHEMA retailhub_trainer.lakeflow_connect TO `dea-training`;
```

KROK 5

Sprawdzenie załadowanych tabel

Po zakończeniu pierwszej aktualizacji pipeline'u ingestii uruchom poniższe zapytania w notebooku lub edytorze SQL. Unity Catalog przechowuje nazwy tabel małymi literami, więc SalesOrderHeader staje się salesorderheader.

```
SHOW TABLES IN retailhub_trainer.lakeflow_connect;

SELECT 'customer' AS table_name, COUNT(*) AS row_count FROM
retailhub_trainer.lakeflow_connect.customer
UNION ALL SELECT 'product', COUNT(*) FROM retailhub_trainer.lakeflow_connect.product
UNION ALL SELECT 'salesorderheader', COUNT(*) FROM
retailhub_trainer.lakeflow_connect.salesorderheader
UNION ALL SELECT 'salesorderdetail', COUNT(*) FROM
retailhub_trainer.lakeflow_connect.salesorderdetail;
```

```
-- Top products by wholesale revenue
SELECT p.Name AS product_name, SUM(d.OrderQty) AS units, ROUND(SUM(d.LineTotal), 2) AS revenue
FROM retailhub_trainer.lakeflow_connect.salesorderdetail d
JOIN retailhub_trainer.lakeflow_connect.product p ON d.ProductID = p.ProductID
GROUP BY p.Name
ORDER BY revenue DESC
LIMIT 10;
```

```
DESCRIBE TABLE EXTENDED retailhub_trainer.lakeflow_connect.customer; -- streaming table owned by
the pipeline
DESCRIBE HISTORY retailhub_trainer.lakeflow_connect.customer LIMIT 5;
```

Porównaj liczby wierszy z wynikiem `SELECT COUNT(*)` na tabelach źródłowych w Azure SQL. Typy danych są konwertowane automatycznie: na przykład `MONEY` staje się `DECIMAL(19,4)`, `DATETIME` staje się `TIMESTAMP`, a `UNIQUEIDENTIFIER` i `XML` stają się `STRING`.

KROK 6

Test przepływu zmian (CDC)

W Databricks zapisz bieżącą wartość:

```
SELECT CustomerID, FirstName, LastName, Phone, ModifiedDate
FROM retailhub_trainer.lakeflow_connect.customer
WHERE CustomerID = 1;
```

Zmień wiersz w Azure SQL, w Query editor w Azure Portal lub przez `sqlcmd`, i sprawdź, czy CDC przechwyciło zmianę. W Azure SQL Database zadanie przechwytywania działa mniej więcej co 20 sekund.

```
UPDATE SalesLT.Customer
SET Phone = '555-TRAINING-42', ModifiedDate = SYSDATETIME()
WHERE CustomerID = 1;

SELECT __$operation, CustomerID, Phone
FROM cdc.SalesLT_Customer_CT
WHERE CustomerID = 1;          -- operation 3 = before update, 4 = after update
```

W **Jobs & Pipelines** otwórz pipeline ingestii i wybierz **Start**. Brama ma już zapisaną zmianę, a aktualizacja scala ją z tabelą docelową. Uruchom ponownie zapytanie w Databricks: **Phone** ma teraz wartość **555-TRAINING-42**. Wstawienia i usunięcia w źródle trafiają do miejsca docelowego w ten sam sposób; przy wyłączonym history tracking wiersz usunięty w źródle znika z tabeli docelowej.

KROK 7

Kontrola kosztów i sprzątanie

Składnik	Za co płacisz	Jak ograniczyć
Brama ingestii	Klasyczne VM i DBU przez cały czas działania	Największy koszt w tym układzie; usuń bramę zaraz po demo
Pipeline ingestii	DBU serverless za każdą aktualizację	Uruchamiaj ręcznie lub rzadko według harmonogramu
Azure SQL Database	Sekundy vCore w czasie działania plus magazyn	Auto-pause po 15 minutach bezczynności; działająca brama utrzymuje bazę aktywną, a uśpiona baza nie przechwytyje zmian przez CDC
Wolumen roboczy i tabele	Magazyn	Usuń schematy po zakończeniu

Dokumentacja Databricks ostrzega przed zatrzymywaniem bramy na produkcji. Jeśli brama stoi dłużej niż okres przechowywania zmian w źródle (dla CDC domyślnie trzy dni), zmiany przepadają i tabele wymagają pełnego odświeżenia. Na krótkim szkoleniu nie ma to znaczenia, więc usuń wszystko zaraz po demo:

1. W **Jobs & Pipelines** usuń pipeline ingestii, a potem bramę.
2. Usuń obiekty Databricks utworzone przez pipeline'y i przez Ciebie:

```
DROP SCHEMA IF EXISTS retailhub_trainer.lakeflow_connect CASCADE;
DROP SCHEMA IF EXISTS retailhub_trainer.lakeflow_staging CASCADE;
DROP CONNECTION IF EXISTS retailhub_sqlserver;
```

3. Po ostatnim dniu szkolenia usuń zasoby Azure i sprawdź, że grupa zasobów zniknęła:

```
cd infra/terraform
terraform destroy
az group list --table | grep dea
```

Podsumowanie

Gdzie	Krok	Wynik
Terminal, Terraform	1. <code>terraform apply</code>	Serwer Azure SQL, baza serverless AdventureWorksLT, reguły firewalla, wartości wyjściowe
sqlcmd	2. <code>create_login_master.sql</code> (własne hasło), <code>enable_cdc.sql</code> , skrypt narzędziowy Databricks	Login i użytkownik <code>lakeflow_connect</code> , CDC na czterech tabelach <code>SalesLT</code> , obiekty DDL support
Catalog, Connections	3. Create connection	Połączenie Unity Catalog <code>retailhub_sqlserver</code>
Data Ingestion, SQL Server	4. Kreator	Brama, wolumen roboczy, pipeline ingestii, uprawnienia dla uczestników
Edytor SQL lub notebook	5. Zapytania kontrolne	Cztery streaming tables w <code>retailhub_trainer.lakeflow_connect</code>
Azure SQL i Jobs & Pipelines	6. UPDATE, potem Start	Zmiana widoczna w tabeli docelowej
Jobs & Pipelines, Terraform	7. Usunięcie, DROP, <code>terraform destroy</code>	Brak pozostawionych zasobów

Rozwiązywanie problemów

Objaw	Przyczyna i rozwiązanie
Przekroczony czas logowania sqlcmd	Twojego adresu IP nie ma w <code>trainer_ip_cidrs</code> (sprawdź przez <code>curl -s ifconfig.me</code> , dodaj i ponownie wykonaj <code>apply</code>) albo baza serverless właśnie się wybudza; spróbuj po około minucie
Test połączenia lub brama nie dociera do serwera	Brak reguły firewalla <code>AllowAzureServices</code> albo błędny host lub port; host musi być pełną nazwą <code>*.database.windows.net</code> , a port to 1433
Pierwsze połączenie po przerwie trwa długo lub kończy się timeoutem	Baza się uśpiła; wybudzenie trwa 30-60 sekund; wykonaj zapytanie tuż przed demo
<code>sp_cdc_enable_db</code> kończy się błędem	Połączenie z master (użyj <code>-d AdventureWorksLT</code>) albo poziom poniżej 1 vCore lub S3; zostaw <code>GP_S_Gen5_1</code> albo przejdź na change tracking
Walidacja zgłasza brak CDC lub change tracking albo brak uprawnień	Uruchom ponownie <code>create_login_master.sql</code> i <code>enable_cdc.sql</code> ; sprawdź <code>SELECT is_tracked_by_cdc FROM sys.tables</code> ; uruchom skrypt narzędziowy Databricks z <code>lakeflowFixPermissions</code>
<code>PERMISSION_DENIED: You are not authorized to create clusters</code>	Użytkownik nie ma uprawnień do tworzenia klastrów bez ograniczeń, którego wymaga brama; musi je nadać administrator workspace'u
Kreator nie pozwala utworzyć połączenia, wolumenu lub tabel	Brak uprawnień Unity Catalog: <code>CREATE CONNECTION</code> , <code>USE CATALOG</code> , <code>CREATE SCHEMA</code> lub <code>USE SCHEMA</code> , <code>CREATE TABLE</code> , <code>CREATE VOLUME</code>
Zapytanie zgłasza, że tabela nie istnieje	Użyj nazw małymi literami (<code>salesorderheader</code>) i schematu docelowego, a nie roboczego; poczekaj na koniec pierwszej aktualizacji
<code>Cannot have multiple queries named ...</code>	Dwa schematy źródłowe mają tabele o tej samej nazwie kierowane do jednego schematu docelowego; ustaw różne nazwy docelowe lub użyj osobnych par bramy i pipeline'u
Zmiana ze źródła się nie pojawia	Zadanie przechwytywania jeszcze nie ruszyło (około 20 sekund), po zmianie nie było aktualizacji ingestii albo baza była uśpiona
<code>NON_INCREMENTAL_SCHEMA_CHANGE</code> po dodaniu kolumny w źródle	Wykonaj pełne odświeżenie tej tabeli ze strony pipeline'u