

PO SZKOLENIU

Dalsze kroki

Przygotowanie do egzaminu, ścieżka rozwoju i funkcje poza egzaminem

Spis treści

CZĘŚĆ 1	Przed egzaminem	3
CZĘŚĆ 2	Ścieżka rozwoju po poziomie Associate	4
CZĘŚĆ 3	Pipeline'y sterowane metadanymi	5
CZĘŚĆ 4	Lakeflow Connect poza SQL Server	6
CZĘŚĆ 5	Tabele systemowe i obserwowalność	7
CZĘŚĆ 6	OpenSharing (dawniej Delta Sharing)	8
CZĘŚĆ 7	Lineage	9
CZĘŚĆ 8	Dashboardy AI/BI i Genie	9
CZĘŚĆ 9	Terraform dla środowiska	10
CZĘŚĆ 10	CI/CD z GitHub Actions i bundle'ami	11

Po tym trzydniowym szkoleniu jesteś przygotowany do egzaminu Databricks Certified Data Engineer Associate. Ten przewodnik podpowiada, co dalej: jak zarezerwować egzamin i się do niego przygotować, jakie certyfikaty i kursy są kolejne po poziomie Associate oraz które funkcje platformy warto poznać, choć egzamin ich nie sprawdza. Większość części odsyła do materiałów z repozytorium szkolenia, z których możesz dalej korzystać.

CZĘŚĆ 1

Przed egzaminem

Rezerwacja

Krok	Szczegóły
Zapoznanie się z egzaminem	databricks.com/learn/certification : strona egzaminu, aktualny przewodnik egzaminacyjny i FAQ
Założenie konta	webassessor.com/databricks , portal rejestracyjny prowadzony przez Kryterion
Rejestracja	<i>Register for an Assessment</i> , wybór Data Engineer Associate, a następnie egzaminu online z nadzorem lub w centrum egzaminacyjnym
Przygotowanie stanowiska	Przy egzaminie online uruchom test systemu na komputerze, którego użyjesz; potrzebne są kamera, ciche pomieszczenie i ważny dokument ze zdjęciem
Po zdaniu	Odnaka i certyfikat pojawiają się w credentials.databricks.com ; są ważne dwa lata

Opłata wynosi 200 USD plus należne podatki. Przed rezerwacją sprawdź w FAQ certyfikacji zasady ponownego podejścia i zmiany terminu, bo mogą się zmieniać. Wybierz termin dwa do czterech tygodni po szkoleniu, póki materiał jest świeży.

Jak się przygotować

1. Przejdź *Mapę celów egzaminu* z tego szkolenia, jedną sekcję na sesję. Dla każdego celu wskazuje notebooki do otwarcia i fakty, które trzeba znać.
2. Powtórz laboratoria bez podpowiedzi, zaczynając od pustej komórki. Odtwarzanie kodu z pamięci daje dużo więcej niż ponowne czytanie rozwiązań.
3. Rozwiąż ponownie quizy szkoleniowe i test próbny z odmierzanym czasem. Przed właściwym egzaminem celuj w co najmniej 80%.
4. Dla każdej błędnej odpowiedzi znajdź odpowiadający jej cel i zapisz, dlaczego wygrywa poprawna opcja. Egzamin opiera się na scenariuszach, więc liczy się rozumowanie, a nie pamięciowa znajomość składni.
5. Dwa tygodnie przed egzaminem pobierz aktualny przewodnik i porównaj go z mapą. Databricks aktualizuje go co kilka miesięcy.

Zalecane kursy Databricks Academy

Przewodnik egzaminacyjny zaleca kurs z instruktorem *Data Engineering with Databricks* oraz poniższe kursy do samodzielnej nauki w Databricks Academy. Korzystaj z nich, by uzupełnić konkretne luki, a nie jako drugiego pełnego kursu.

Kurs do samodzielnej nauki	Sekcje egzaminu
Data Ingestion with Lakeflow Connect	2 Data Ingestion and Loading
Build Data Pipelines with Lakeflow Spark Declarative Pipelines	2, 3 Data Transformation and Modeling
Deploy Workloads with Lakeflow Jobs	4 Working with Lakeflow Jobs, 6 Troubleshooting
DevOps Essentials for Data Engineering	5 Implementing CI/CD
Data Interoperability with Unity Catalog	1 Platform, 7 Governance and Security
Get Started with Data Governance on Databricks	7 Governance and Security

Databricks Academy jest dostępna pod adresem databricks.com/learn/training. Konta partnerów i klientów mogą mieć dostęp do dodatkowych materiałów.

CZĘŚĆ 2

Ścieżka rozwoju po poziomie Associate

Certyfikaty

Certyfikat	Zakres	Kiedy ma sens
Data Engineer Professional	Zaawansowane pipeline'y, wydajność, bezpieczeństwo, testowanie i wdrażanie na dużą skalę	Po około roku produkcyjnej pracy z Databricks
Associate Developer for Apache Spark	DataFrame API i Spark SQL, niezależnie od platformy	Jeśli pracujesz ze Sparkiem także poza Databricks
Data Analyst Associate	Databricks SQL, dashboardy, analityka	Jeśli wspierasz zespoły BI lub budujesz dashboardy
Machine Learning Associate i Professional	Przygotowanie cech, MLflow, wdrażanie modeli	Jeśli idziesz w stronę inżynierii ML
Generative AI Engineer Associate	RAG, agenci, model serving	Jeśli budujesz aplikacje LLM na Databricks
Akredytacje Platform Administrator i Platform Architect	Administracja workspace'ami, architektura w Azure, AWS lub GCP	Jeśli odpowiadasz za konfigurację platformy

Pełna lista, łącznie z nowszymi certyfikatami, jest na databricks.com/learn/certification. Przed wyborem kolejnego egzaminu porównaj jego aktualny przewodnik ze swoją codzienną pracą.

Praktyka bez firmowego workspace'u

Databricks Free Edition zastępuje dawną Community Edition. Daje workspace wyłącznie z zasobami serverless, z domyślnym magazynem, Unity Catalog, notebookami, jobami, pipeline'ami, SQL i AI/BI. Użycie ograniczają limity na konto, dostęp do internetu jest zawężony do zaufanych domen, a zastosowania komercyjne są niedozwolone. Dobrze nadaje się do powtarzania laboratoriów z tego szkolenia. Rejestracja: databricks.com/learn/free-edition.

Inne możliwości: 14-dniowy workspace próbny w Azure, AWS lub GCP albo workspace zbudowany z **infra/terraform** z tego repozytorium (część 9).

CZĘŚĆ 3

Pipeline'y sterowane metadany

Na szkoleniu każdy zbiór danych miał własny kod pipeline'u. W prawdziwych projektach często ładuje się dziesiątki lub setki podobnych źródeł. Pipeline **sterowany metadany** na starcie aktualizacji czyta tabelę konfiguracyjną i generuje zbiory danych w pętli. Dodanie nowego źródła oznacza wtedy wstawienie jednego wiersza, a nie pisanie nowego kodu.

Działający przykład znajdziesz w `materials/lakeflow/lakeflow_metadata_driven.00_create_config_table.py` tworzy `sdp_meta.pipeline_config`, a `transformations/01_dynamic_pipeline.py` buduje na jej podstawie tabele `bronze` i `silver`.

```
from pyspark import pipelines as dp
from pyspark.sql import functions as F

SOURCE_PATH = spark.conf.get("source_path")
rows = [r.asDict() for r in spark.read.table(spark.conf.get("config_table"))
        .where("active = true").collect()]

def make_bronze(cfg):
    @dp.table(name=f"bronze_{cfg['entity']}_dyn")
    def _bronze(cfg=cfg):
        # default argument pins this row's values
        return (spark.readStream.format("cloudFiles")
                .option("cloudFiles.format", cfg["source_format"])
                .load(f"{SOURCE_PATH}/{cfg['source_subdir']}")
                .withColumn("_ingest_ts", F.col("_metadata.file_modification_time")))

    return _bronze

for cfg in rows:
    make_bronze(cfg)
```

Kwestia projektowa	Zalecenie
Konfiguracja	Tabela Delta lub plik YAML w Git, z kolumnami: encja, ścieżka, format, klucze, typ ładowania i expectations w JSON
Domknięcia w pętli	Każdy zbiór opakuj w funkcję fabrykującą, przekaż wiersz jako argument domyślny i ustaw jawne name=
Zmiany	Konfiguracja jest czytana na starcie aktualizacji; nowy wiersz pojawia się przy następnej
Reguły jakości	Przechowuj expectations w konfiguracji i stosuj przez <code>dp.expect_all_or_drop</code>
Kiedy nie stosować	Mniej niż około dziesięć źródeł albo źródła wymagające bardzo różnej logiki; zwykły kod jest czytelniejszy

CZĘŚĆ 4

Lakeflow Connect poza SQL Server

Na szkoleniu pokazaliśmy zarządzany konektor SQL Server (zob. przewodnik praktyczny *Lakeflow Connect*). Lakeflow Connect obsługuje też inne typy źródeł.

Typ konektora	Przykłady	Składniki
Bazy danych (CDC)	SQL Server, MySQL, PostgreSQL, Oracle	Połączenie, brama ingestii, wolumen roboczy, pipeline ingestii
Aplikacje SaaS	Salesforce, Workday, ServiceNow, Dynamics 365, HubSpot, Jira	Połączenie i pipeline ingestii
Firmowe usługi plikowe	SharePoint, Google Drive	Połączenie i pipeline ingestii; pliki binarne lub parsowane
Oparte na zapytaniach	Bazy, w których nie da się włączyć CDC	Cykliczne zapytania po kolumnie kursora
Strumieniowe	Kafka, RabbitMQ i inne magistrale komunikatów	Ciągła ingestia
Bezpośredni zapis	Zerobus Ingest API	Aplikacje zapisują rekordy wprost do streaming tables

Konektory są na różnych etapach dostępności, więc przed planowaniem projektu sprawdź ich listę w dokumentacji dla swojej chmury. Każdy konektor zarządzany można zdefiniować w bundle'u. Poniższy szkielecik pokazuje dwa pipeline'y konektora bazodanowego:

```
resources:
  pipelines:
    sqlserver_gateway:
      name: lfc-sqlserver-gateway-${bundle.target}
      continuous: true # the gateway must run continuously
      catalog: ${var.staging_catalog}
      schema: ${var.staging_schema}
      gateway_definition:
        connection_name: retailhub_sqlserver
        gateway_storage_catalog: ${var.staging_catalog}
        gateway_storage_schema: ${var.staging_schema}
    sqlserver_ingestion:
      name: lfc-sqlserver-ingestion-${bundle.target}
      serverless: true
      catalog: ${var.dest_catalog}
      schema: ${var.dest_schema}
      ingestion_definition:
        ingestion_gateway_id: ${resources.pipelines.sqlserver_gateway.id}
      objects:
        - schema:
            source_catalog: AdventureWorksLT
            source_schema: SalesLT
            destination_catalog: ${var.dest_catalog}
            destination_schema: ${var.dest_schema}
```

Pipeline ingestii odświeża następnie job z zadaniem `pipeline_task` i harmonogramem. Jeśli bazę trzeba tylko od czasu do czasu odpytać bez kopiowania danych, zamiast ingestii użyj Lakehouse Federation.

CZĘŚĆ 5

Tabele systemowe i obserwowalność

Tabele systemowe w katalogu `system` rejestrują zużycie, joby, dostęp i lineage dla całego konta. Dostęp nadaje administrator konta, np. `USE CATALOG na system` i `SELECT` na potrzebnych schematach.

Tabela	Na jakie pytanie odpowiada
<code>system.billing.usage</code> , <code>system.billing.list_prices</code>	Zużycie DBU według workspace'u, joba, pipeline'u, warehouse'u lub tagu oraz cena katalogowa
<code>system.lakeflow.jobs</code> , <code>job_run_timeline</code> , <code>job_task_run_timeline</code>	Spis jobów, wyniki uruchomień i trendy czasu trwania
<code>system.lakeflow.pipelines</code>	Spis pipeline'ów
<code>system.access.audit</code>	Kto co uruchomił, zmienił lub komu nadał uprawnienia i kiedy
<code>system.access.table_lineage</code> , <code>column_lineage</code>	Które joby, notebooki i zapytania czytają i zapisują daną tabelę
<code>system.compute.clusters</code> , <code>warehouses</code>	Historia konfiguracji zasobów
<code>system.storage.predictive_optimization_operations_history</code>	Automatyczne operacje <code>OPTIMIZE</code> , <code>VACUUM</code> i <code>ANALYZE</code>

```
-- DBUs per job over the last 30 days
SELECT usage_metadata.job_id, sku_name, SUM(usage_quantity) AS dbus
FROM system.billing.usage
WHERE usage_metadata.job_id IS NOT NULL
      AND usage_date >= current_date() - INTERVAL 30 DAYS
GROUP BY ALL
ORDER BY dbus DESC;

-- Recent permission changes
SELECT event_time, user_identity.email, action_name, request_params
FROM system.access.audit
WHERE service_name = 'unityCatalog' AND action_name LIKE '%Permissions%'
ORDER BY event_time DESC
LIMIT 50;
```

Zapisz takie zapytania w edytorze SQL, dodaj alert (np. gdy wczorajsze zużycie DBU przekroczy próg) i zbierz je w dashboard AI/BI dla zespołu. Własne tagi na jobach, pipeline'ach i warehouse'ach trafiają do system.billing.usage i ułatwiają rozliczanie kosztów według projektów.

CZĘŚĆ 6

OpenSharing (dawniej Delta Sharing)

OpenSharing udostępnia tabele, widoki, wolumeny, modele i notebooki innym organizacjom bez kopiowania danych. **Udostępnianie Databricks-to-Databricks** łączy dwa metastore'y Unity Catalog przez identyfikator udostępniania. **Open sharing** obsługuje dowolnych klientów, np. Spark, pandas czy Power BI, przez token bearer lub federację OIDC.

```
CREATE SHARE retail_partner_share COMMENT 'Daily revenue for the partner';
ALTER SHARE retail_partner_share ADD TABLE main.gold.daily_revenue;

-- Databricks-to-Databricks: the recipient sends you its sharing identifier
CREATE RECIPIENT partner_co USING ID 'azure:westeurope:<metastore-uuid>';
GRANT SELECT ON SHARE retail_partner_share TO RECIPIENT partner_co;

SHOW GRANTS ON SHARE retail_partner_share;
```

Odbiorca tworzy z udziału katalog i odpytuje go jak każdy inny. Udostępnianie w obrębie jednego konta Databricks jest zawsze włączone; udostępnianie innym kontom lub klientom spoza Databricks trzeba włączyć na metastore. Tworzenie odbiorców wymaga **CREATE RECIPIENT** na metastore. OpenSharing jest też podstawą Databricks Marketplace i Clean Rooms.

CZĘŚĆ 7

Lineage

Unity Catalog automatycznie rejestruje lineage dla zapytań uruchamianych na zasobach z Unity Catalog: które tabele, kolumny, notebooki, joby, pipeline'y i dashboardy czytają lub zapisują dany obiekt. Nie wymaga to żadnego dodatkowego kodu.

- **Catalog Explorer:** otwórz tabelę, wybierz **Lineage**, a potem **See lineage graph**. Kliknij kolumnę, aby zobaczyć kolumny, z których powstała.
- **Tabele systemowe:** `system.access.table_lineage` i `system.access.column_lineage` przechowują dane z ostatniego roku do analizy wpływu zmian w SQL.

```
-- Everything that wrote to or read from the silver orders table in the last week
SELECT entity_type, entity_id, source_table_full_name, target_table_full_name, event_time
FROM system.access.table_lineage
WHERE (source_table_full_name = 'main.silver.orders' OR target_table_full_name =
'main.silver.orders')
AND event_date >= current_date() - INTERVAL 7 DAYS
ORDER BY event_time DESC;
```

Sprawdź lineage przed zmianą lub usunięciem tabeli, żeby zobaczyć, których jobów i dashboardów to dotknie. Tabele używane tylko przez ścieżkę są rejestrowane pod ścieżką, a nie nazwą. Dla systemów spoza Databricks external lineage pozwala ręcznie dodać obiekty źródłowe i docelowe.

CZĘŚĆ 8

Dashboardy AI/BI i Genie

Notebook dodatkowy `BONUS_aibi_dashboards` pokazuje oba narzędzia na tabelach gold RetailHub.

Narzędzie	Co robi	Wskazówki
Dashboardy AI/BI	Zbiory danych w SQL, wizualizacje, filtry i parametry; publikacja z osadzonymi poświadczeniami lub poświadczeniami oglądającego; odświeżanie według harmonogramu i subskrypcje e-mail	Buduj na tabelach gold lub materialized views; odświeżaj z joba zadaniem Dashboard po zakończeniu pipeline'u
Przestrzeń Genie	Użytkownicy biznesowi zadają pytania w języku naturalnym; Genie generuje SQL na wybranych tabelach	Zaczynaj od kilku dobrze opisanych tabel; dodaj komentarze kolumn, przykładowe pytania, instrukcje i zaufane zapytania SQL; przeglądaj pytania, które faktycznie padają

Oba narzędzia działają na SQL warehouse i respektują uprawnienia Unity Catalog, filtry wierszy i maski kolumn. Użytkownik widzi tylko dane, które może odpytać, chyba że dashboard opublikowano z osadzonymi poświadczeniami autora.

CZĘŚĆ 9

Terraform dla środowiska

Środowisko szkoleniowe jest opisane jako kod w `infra/terraform`. Traktuj je jako punkt wyjścia dla własnej piaskownicy lub środowiska zespołu.

Plik	Tworzy
<code>main.tf, variables.tf</code>	Nazwy z losowym sufiksem, tagi (w tym <code>auto-delete-after</code>), grupę zasobów
<code>storage.tf</code>	Konto ADLS Gen2 z kontenerami <code>raw</code> i <code>external</code> , Access Connector, rolę Storage Blob Data Contributor
<code>databricks_workspace.tf</code>	Workspace Premium (opcjonalnie; nowe workspace'y mają 14-dniowy okres próbny DBU)
<code>databricks_uc.tf</code>	Storage credential, external location i uprawnienia (gdy <code>configure_uc = true</code>)
<code>sql_server.tf</code>	Serwer Azure SQL, bazę serverless AdventureWorksLT i reguły firewalla dla Lakeflow Connect

```
cd infra/terraform
cp terraform.tfvars.example terraform.tfvars    # set prefix, passwords, IP addresses, dates
terraform init
terraform plan
terraform apply
terraform destroy                                # after the training; removes everything
```

```
resource "databricks_external_location" "external" {
  provider      = databricks.workspace
  name          = "el-${var.prefix}-training-external"
  url           = local.external_location_url
  credential_name = databricks_storage_credential.external[0].name
}
```

Dalsze kroki z IaC: zarządzaj katalogami, schematami, grupami i uprawnieniami przez provider Databricks (`databricks_catalog`, `databricks_schema`, `databricks_grants`); trzymaj stan w zdalnym backendzie, np. w kontenerze Azure Storage z blokadą; uruchamiaj plan w CI przy pull requestach. W uproszczeniu: Terraform zarządza platformą (workspace'y, magazyn, obiekty Unity Catalog, tożsamości), a bundle'e obciążeniami (joby, pipeline'y, dashboardy).

CZĘŚĆ 10

CI/CD z GitHub Actions i bundle'ami

W module 09 wdrażaliśmy `materials/cicd` z terminala. W zespole te same polecenia uruchamia CI przy otwarciu lub scaleniu pull requesta.

```
# .github/workflows/deploy.yml
name: Deploy RetailHub bundle
on:
  pull_request:
    branches: [main]
  push:
    branches: [main]

jobs:
  deploy:
    runs-on: ubuntu-latest
    env:
      DATABRICKS_HOST: ${vars.DATABRICKS_HOST}
      DATABRICKS_CLIENT_ID: ${secrets.SP_CLIENT_ID} # service principal, OAuth M2M
      DATABRICKS_CLIENT_SECRET: ${secrets.SP_CLIENT_SECRET}
    defaults:
      run:
        working-directory: materials/cicd
    steps:
      - uses: actions/checkout@v4
      - uses: databricks/setup-cli@main
      - run: databricks bundle validate -t test
      - if: github.event_name == 'pull_request'
        run: databricks bundle deploy -t test
      - if: github.event_name == 'push'
        run: |
          databricks bundle validate -t prod
          databricks bundle deploy -t prod
```

Praktyka	Dlaczego
Wdrażaj jako service principal, nigdy osobistym tokenem	Wdrożenia nie przestają działać, gdy ktoś odchodzi, a uprawnienia są minimalne
Wybieraj workload identity federation (GitHub OIDC) zamiast sekretów klienta	W repozytorium nie ma długo żyjącego sekretu
Dodaj target test i po wdrożeniu uruchamiaj testy integracyjne, np. <code>databricks bundle run -t test retailhub_job</code>	Błędy wychodzą przed produkcją
Chroń środowisko produkcyjne w GitHub wymaganymi recenzentami	Każde wdrożenie produkcyjne zatwierdza człowiek
Zostaw mode: production i run_as w targecie prod	Zasoby produkcyjne nie są przemianowywane ani wstrzymywane i działają pod stałą tożsamością

Target prod w `materials/cicd/databricks.yml` jest zakomentowanym szkieletem. Zanim użyjesz tego workflow, odkomentuj go i ustaw host, ścieżkę główną, zmienne i service principal.

Materialy

Material	Adres
Dokumentacja (Azure)	learn.microsoft.com/azure/databricks
Dokumentacja (wszystkie chmury)	docs.databricks.com
Certyfikacja	databricks.com/learn/certification
Rejestracja na egzamin	webassessor.com/databricks
Databricks Academy	databricks.com/learn/training
Free Edition	databricks.com/learn/free-edition
Forum społeczności	community.databricks.com
Provider Terraform	registry.terraform.io/providers/databricks/databricks
Szablony bundle'i i CLI	github.com/databricks/cli