

SPRAWDZENIE WIEDZY

Databricks Data Engineer Associate

Quizy ze wszystkich trzech dni z kluczem odpowiedzi

Quiz zawiera 68 pytań jednokrotnego wyboru ze wszystkich trzech dni szkolenia: 20 z dnia 1, 20 z dnia 2 i 28 z dnia 3. Pytania są numerowane w sposób ciągły i mają styl zbliżony do pytań egzaminu certyfikacyjnego. W każdym pytaniu wybierz jedną, najlepszą odpowiedź. Klucz odpowiedzi znajduje się na ostatniej stronie.

DZIEŃ 1

Dzień 1 – Platforma, ingestia i Delta Lake

1. Który komponent platformy Databricks Lakehouse pełni rolę centralnej warstwy nadzoru nad danymi, użytkownikami i uprawnieniami?
 - A. Databricks Runtime
 - B. Delta Lake
 - C. Unity Catalog
 - D. Photon Engine
2. Jaka jest poprawna hierarchia obiektów zabezpieczanych w Unity Catalog, od najszerszego do najbardziej szczegółowego?
 - A. Catalog > Schema > Table
 - B. Schema > Catalog > Table
 - C. Metastore > Schema > Catalog
 - D. Workspace > Catalog > Table
3. Użytkownik, który nie jest właścicielem żadnych obiektów, musi odpytać tabelę `sales.bronze.orders` w Unity Catalog. Jaki jest minimalny zestaw uprawnień, którego potrzebuje?
 - A. Tylko `SELECT` na tabeli
 - B. Tylko `USE CATALOG` na `sales` i `USE SCHEMA` na `sales.bronze`
 - C. `USE CATALOG` na `sales`, `USE SCHEMA` na `sales.bronze` i `SELECT` na tabeli
 - D. `BROWSE` na katalogu
4. Które polecenie SQL odczytuje dane z pliku CSV w wolumenie Unity Catalog i tworzy zarządzaną tabelę Delta?
 - A. `LOAD DATA INPATH '/path' INTO TABLE t`
 - B. `COPY INTO t FROM '/path'`
 - C. `INSERT INTO t VALUES (SELECT * FROM '/path')`
 - D. `CREATE TABLE t AS SELECT * FROM read_files('/path', format => 'csv')`
5. Które stwierdzenie o tabelach zarządzanych (managed) i zewnętrznych (external) w Unity Catalog jest prawdziwe?
 - A. Tabele zarządzane przechowują dane we wskazanej przez użytkownika lokalizacji w chmurze
 - B. Dane tabel zewnętrznych są usuwane po usunięciu tabeli
 - C. Tabele zarządzane przechowują dane w magazynie zarządzanym katalogu, a `DROP` usuwa dane
 - D. Tabel zewnętrznych nie można zarejestrować w Unity Catalog

6. Data engineer chce wykonać transformację SQL na DataFrame `df`. Która sekwencja jest poprawna?

A.

```
df.createOrReplaceTempView("v")
spark.sql("SELECT * FROM v")
```

B.

```
df.registerTable("v")
spark.sql("SELECT * FROM v")
```

C.

```
df.saveAsTable("v")
spark.sql("SELECT * FROM v")
```

D. `spark.sql("CREATE VIEW v AS df")`

7. Co gwarantuje dziennik transakcji Delta Lake?

- A. Semantykę exactly-once wyłącznie dla odczytów wsadowych
- B. Transakcje ACID, time travel i wymuszanie schematu
- C. Wyłącznie automatyczną kompresję danych
- D. Rozproszone buforowanie wyników zapytań

8. W jakim formacie plików Delta Lake przechowuje dane?

- A. Parquet
- B. ORC
- C. JSON
- D. Avro

9. Polecenie `DESCRIBE HISTORY` na tabeli Delta pokazuje 5 wersji. Co reprezentuje każda wersja?

- A. Wyłącznie zmianę schematu
- B. Operację transakcyjną (zapis, update, delete, merge, optimize itp.)
- C. Sesję użytkownika
- D. Wykonanie zaplanowanego joba

10. Data engineer uruchamia poniższe zapytanie. Co ono zwraca?

```
SELECT * FROM my_table VERSION AS OF 3
```

- A. Tabelę w stanie z wersji transakcji 3
- B. Bieżącą tabelę ograniczoną do 3 wierszy
- C. Trzecią partycję tabeli
- D. Błąd, ponieważ time travel nie jest obsługiwany

11. Zespół 40 analityków biznesowych równocześnie uruchamia zapytania SQL i dashboardy Power BI w godzinach pracy, a w nocy nic nie działa. Zespół oczekuje szybkiego startu, automatycznego skalowania przy wielu równoczesnych zapytaniach i braku infrastruktury do utrzymania. Które zasoby obliczeniowe są najodpowiedniejsze?

- A. Klaster all-purpose z procesorami GPU
- B. Jednowęzłowy klaster all-purpose współdzielony przez wszystkich analityków
- C. Nowy klaster job tworzony przy każdym odświeżeniu dashboardu
- D. Serverless SQL warehouse

12. Jaki jest zalecany sposób przechowywania plików nietabelarycznych (CSV, JSON, obrazy) w Unity Catalog?

- A. DBFS root
- B. Mounty DBFS
- C. Wolumeny Unity Catalog
- D. Lokalny dysk klastra

13. Czym różni się ELT od ETL w kontekście Databricks Lakehouse?

- A. To ten sam proces
- B. ELT służy tylko do przetwarzania wsadowego, a ETL do streamingu
- C. ELT wymaga zewnętrznych narzędzi, a ETL jest natywny
- D. W ELT surowe dane są najpierw ładowane, a potem transformowane na miejscu; w ETL dane są transformowane przed załadowaniem

14. Co zwraca `DESCRIBE DETAIL my_table`, czego nie zwraca `DESCRIBE TABLE my_table`?

- A. Nazwy kolumn i typy danych
- B. Lokalizację tabeli, liczbę plików, rozmiar w bajtach, informacje o partycjonowaniu i właściwości tabeli
- C. Definicję SQL tabeli
- D. Uprawnienia dostępu

15. Na klasycznym klastrze data engineer uruchamia poniższe polecenia. Jaki jest ich wpływ na time travel?

```
SET spark.databricks.delta.retentionDurationCheck.enabled = false;  
VACUUM my_table RETAIN 0 HOURS;
```

- A. Brak wpływu — time travel nadal działa dla wszystkich wersji
- B. Błąd — `VACUUM` wymaga retencji co najmniej 168 godzin
- C. Czyszczona jest tylko najnowsza wersja
- D. Wszystkie historyczne pliki danych zostają usunięte; time travel do starszych wersji zakończy się błędem

16. Co robi polecenie magiczne `%run` w notebooku Databricks?

- A. Uruchamia zewnętrzny skrypt Python na węźle driver
- B. Wykonuje inny notebook w tym samym kontekście wykonania, udostępniając jego zmienne i funkcje
- C. Uruchamia zapytanie SQL i zwraca wyniki
- D. Restartuje klaster i uruchamia wszystkie komórki

17. Przychodzący DataFrame `df` zawiera kolumnę, której nie ma w tabeli Delta `my_table`. Co się stanie po uruchomieniu tego kodu?

```
df.write.mode("append").saveAsTable("my_table")
```

- A. Nowa kolumna zostanie po cichu pominięta
- B. Cała tabela zostanie odtworzona z nowym schematem
- C. Nowa kolumna zostanie automatycznie dodana do tabeli
- D. Zapis zakończy się błędem niezgodności schematu (wymuszanie schematu)

18. Który moduł `dbutils` udostępnia metody do listowania, kopiowania i usuwania plików?

- A. `dbutils.fs.ls("/path")`
- B. `dbutils.data.list("/path")`
- C. `dbutils.files.browse("/path")`
- D. `dbutils.storage.ls("/path")`

19. Co robi polecenie `RESTORE TABLE my_table TO VERSION AS OF 2`?

- A. Tworzy kopię wersji 2 jako nową tabelę
- B. Usuwa wszystkie wersje późniejsze niż 2
- C. Przywraca tabelę do stanu z wersji 2, dodając nową wersję do historii
- D. Wyświetla tabelę w wersji 2 bez jej modyfikowania

20. Które polecenie poprawnie odczytuje plik JSON z jawnie zdefiniowanym schematem w PySpark?

A. `df = spark.read.json("/path/data.json").schema("id INT, name STRING")`

B.

```
from pyspark.sql.types import StructType, StructField, IntegerType, StringType
schema = StructType([StructField("id", IntegerType()), StructField("name", StringType())])
df = spark.read.schema(schema).json("/path/data.json")
```

C. `df = spark.read.format("json").option("schema", "id:int, name:string").load("/path")`

D. `df = spark.read.json("/path").cast("id INT, name STRING")`

DZIEŃ 2

Dzień 2 – Optymalizacja, ingestia przyrostowa i transformacje

21. Co robi polecenie `OPTIMIZE` na tabeli Delta?

- A. Scala małe pliki w większe pliki o optymalnym rozmiarze
- B. Usuwa stare wersje z dziennika transakcji
- C. Dodaje indeksy do wszystkich kolumn
- D. Konwertuje tabelę z formatu Parquet do Delta

22. Join tabeli `orders` (400 MB) z wymiarem `products` (25 MB) wykonuje się jako sort-merge join z dużym shufflem. Data engineer chce, aby w tej sesji Spark automatycznie rozgłaszał (broadcast) tabelę `products`, i chce potwierdzić, że zmiana faktycznie pomaga. Co powinien zrobić?

- A. Ustawić `spark.sql.autoBroadcastJoinThreshold` na `-1` i ponownie uruchomić zapytanie
- B. Zwiększyć `spark.sql.shuffle.partitions` do 2000 i założyć, że join jest teraz szybszy
- C. Podnieść `spark.sql.autoBroadcastJoinThreshold` powyżej rozmiaru `products` (na przykład do 50 MB), ponownie uruchomić zapytanie i porównać plan fizyczny oraz czas wykonania z poprzednim uruchomieniem
- D. Wywołać `orders_df.cache()` przed joinem; pomiar nie jest potrzebny

23. Co robi `VACUUM` na tabeli Delta?

- A. Usuwa zduplikowane wiersze
- B. Usuwa pliki danych, do których dziennik transakcji już się nie odwołuje (starsze niż próg retencji)
- C. Kompresuje dziennik transakcji
- D. Przelicza statystyki tabeli

24. Która funkcja Delta Lake zastępuje tradycyjne partycjonowanie i Z-Ordering automatyczną optymalizacją układu danych?

- A. Auto Optimize
- B. Predictive Optimization
- C. Liquid Clustering
- D. Adaptive Query Execution

25. Strumień Auto Loader pobiera pliki JSON z lokalizacji docelowej, która zawiera już miliony plików, a co godzinę dochodzą tysiące nowych. Większość czasu każdego mikrobatcha zajmuje ustalanie, które pliki są nowe. Która zmiana rozwiązuje ten problem?

- A. Przejście z trybu directory listing na tryb file notification, najlepiej z file events (`cloudFiles.useManagedFileEvents`), dzięki czemu nowe pliki są wykrywane na podstawie zdarzeń magazynu zamiast listowania katalogu
- B. Zastąpienie Auto Loadera zaplanowanym `COPY INTO`, które skanuje tę samą lokalizację
- C. Usunięcie `cloudFiles.schemaLocation`, aby schemat nie był już śledzony
- D. Ustawienie `cloudFiles.inferColumnTypes` na `false`

26. Czym różni się widok tymczasowy (temporary view) od widoku trwałego (permanent view) w Databricks?

- A. Widoki tymczasowe są przechowywane w Unity Catalog, a trwałe nie
- B. Widoki tymczasowe istnieją tylko w obrębie SparkSession; widoki trwałe są zapisane w metastore
- C. Widoki tymczasowe obsługują tylko SQL, a trwałe tylko PySpark
- D. Nie ma między nimi różnicy

27. Jaką rolę pełni katalog checkpointów w Structured Streaming?

- A. Przechowuje dane wyjściowe
- B. Buforuje schemat strumienia
- C. Śledzi, które dane zostały już przetworzone, co umożliwia semantykę exactly-once
- D. Rejestruje zapytania użytkowników

28. Która opcja Auto Loadera określa format pobieranych plików?

- A. `cloudFiles.path`
- B. `cloudFiles.format`
- C. `cloudFiles.schemaLocation`
- D. `cloudFiles.inferColumnTypes`

29. Co robi `trigger(availableNow=True)` w zapytaniu strumieniowym?

- A. Uruchamia strumień w sposób ciągły w mikrobatach
- B. Uruchamia dokładnie jeden mikrobata, a potem wstrzymuje działanie
- C. Czeka na nowe dane bez końca
- D. Przyrostowo przetwarza wszystkie dostępne dane, a następnie się zatrzymuje

30. Czym różnią się `COPY INTO` i Auto Loader przy przyrostowej ingestii plików?

- A. `COPY INTO` używa file notification, a Auto Loader directory listing
- B. `COPY INTO` przechowuje stan w checkpointie, a Auto Loader w dzienniku Delta
- C. `COPY INTO` śledzi przetworzone pliki w dzienniku Delta (idempotentny SQL); Auto Loader używa checkpointów i skaluje się do milionów plików
- D. Nie ma różnicy; to aliasy

31. Który fragment poprawnie definiuje strumień odczytu Auto Loadera?

A.

```
spark.readStream.format("cloudFiles") \
    .option("cloudFiles.format", "json") \
    .option("cloudFiles.schemaLocation", checkpoint) \
    .load("/source/path")
```

B.

```
spark.read.format("autoLoader") \
    .option("format", "json") \
    .load("/source/path")
```

C.

```
spark.readStream.format("autoLoader") \
    .option("fileFormat", "json") \
    .load("/source/path")
```

D.

```
spark.readStream.format("delta") \
    .option("autoLoader", True) \
    .load("/source/path")
```

32. Do czego służy Predictive Optimization w Databricks?

- A. Przewiduje czas wykonania zapytań
- B. Prognozuje koszty przechowywania na kolejny miesiąc
- C. Optymalizuje autoskalowanie klastrów
- D. Automatycznie uruchamia `OPTIMIZE`, `VACUUM` i `ANALYZE TABLE` na podstawie wzorców użycia tabel

33. Co poprawiają Deletion Vectors w Delta Lake?

- A. Wydajność `INSERT`
- B. Wydajność `DELETE`, `UPDATE` i `MERGE` dzięki oznaczaniu wierszy jako usuniętych bez przepisywania plików
- C. Wydajność `SELECT` dla agregacji
- D. Szybkość `VACUUM`

34. Która konstrukcja SQL tworzy sumę narastającą `amount` uporządkowaną według `date` w obrębie każdej kategorii `category`?

- A. `SUM(amount) GROUP BY category`
- B. `CUMSUM(amount) WITHIN GROUP (ORDER BY date)`
- C. `RUNNING_SUM(amount, category, date)`
- D.

```
SUM(amount) OVER (  
  PARTITION BY category  
  ORDER BY date  
  ROWS BETWEEN UNBOUNDED PRECEDING AND CURRENT ROW  
)
```

35. Co robi funkcja `explode()`?

- A. Zamienia każdy element tablicy lub mapy w osobny wiersz
- B. Dzieli tekst według separatora na wiele wierszy
- C. Spłaszcza zagnieżdżony JSON do płaskiego schematu
- D. Dekompresuje skompresowane kolumny

36. Dwa miesięczne wyciągi, `orders_jan` i `orders_feb`, mają identyczne kolumny. Data engineer musi połączyć je w SQL, zachowując każdy wiersz (także wiersze występujące w obu), bez kosztu eliminacji duplikatów. Którego zapytania powinien użyć?

- A. `SELECT * FROM orders_jan UNION SELECT * FROM orders_feb`
- B. `SELECT * FROM orders_jan UNION ALL SELECT * FROM orders_feb`
- C. `SELECT * FROM orders_jan CROSS JOIN orders_feb`
- D. `SELECT * FROM orders_jan INNER JOIN orders_feb USING (order_id)`

37. Która funkcja okna nadaje każdemu wierszowi w partycji unikalny kolejny numer, bez luk?

- A. `RANK()`
- B. `DENSE_RANK()`
- C. `NTILE()`
- D. `ROW_NUMBER()`

38. W tabeli z miliardami wierszy analityk potrzebuje liczby unikalnych wartości `customer_id` w każdym segmencie; wynik z dokładnością do kilku procent jest akceptowalny, jeśli zapytanie działa szybko. Chce też jednym wywołaniem uzyskać liczbę, średnią, odchylenie standardowe, minimum, kwartyle i maksimum kolumny `total_amount`. Które połączenie pasuje najlepiej?

- A. `count("customer_id")` i `df.select("total_amount").summary()`
- B. `count_distinct("customer_id")` i `df.select("total_amount").describe()`
- C. `approx_count_distinct("customer_id")` i `df.select("total_amount").summary()`
- D. `approx_count_distinct("customer_id")` i `df.select("total_amount").explain()`

39. W Spark UI etap sort-merge join pokazuje 199 zadań kończących się w około 5 sekund i jedno zadanie działające 14 minut. W Summary Metrics maksymalny shuffle read wynosi 9 GB, a mediana 40 MB. Jaka jest najbardziej prawdopodobna przyczyna i który wbudowany mechanizm jest przeznaczony do jej obsługi?

- A. Skośność danych (data skew) na kluczu joina; obsługa skew join w Adaptive Query Execution dzieli zbyt dużą partycję na mniejsze zadania
- B. Za mało pamięci na każdym executorze; należy zwiększyć `spark.executor.memory` na wszystkich węzłach
- C. Za dużo partycji shuffle; należy ustawić `spark.sql.shuffle.partitions` na 1
- D. Za dużo małych plików w tabelach źródłowych; należy uruchomić `VACUUM` na obu tabelach

40. Data engineer ma DataFrame ze zduplikowanymi wierszami. Która metoda PySpark usuwa duplikaty na podstawie podzbioru kolumn?

- A. `df.distinct()`
- B. `df.unique(["customer_id"])`
- C. `df.removeDuplicates(["customer_id"])`
- D. `df.dropDuplicates(["customer_id", "email"])`

DZIEŃ 3

Dzień 3 – Pipeline'y, joby, CI/CD, diagnostyka i nadzór

41. Która warstwa architektury medalionowej zawiera surowe, niezwalidowane dane pobrane z systemów źródłowych?

- A. Silver
- B. Gold
- C. Bronze
- D. Platinum

42. Czym w Lakeflow Spark Declarative Pipelines różni się STREAMING TABLE od MATERIALIZED VIEW?

- A. STREAMING TABLE obsługuje tylko przetwarzanie wsadowe, a MATERIALIZED VIEW tylko streaming
- B. STREAMING TABLE przetwarza tylko wiersze wejściowe, które pojawiły się od ostatniej aktualizacji (źródła typu append-only); MATERIALIZED VIEW przy każdym odświeżeniu utrzymuje aktualny zapisany wynik swojego zapytania
- C. Są identyczne; nazwy można stosować zamiennie
- D. STREAMING TABLE przechowuje widoki, a MATERIALIZED VIEW tabele

43. Jak w Lakeflow Spark Declarative Pipelines (domyślny tryb publikowania) zazwyczaj odwołuje się do innego zbioru danych zdefiniowanego w tym samym pipeline?

- A. Przez ścieżkę w magazynie chmurowym do plików zbioru danych
- B. Przez prefiks LIVE., wymagany w każdym pipeline
- C. Przez prefiks PIPELINE.
- D. Bezpośrednio przez nazwę zbioru danych (np. FROM bronze_orders), rozwiązywaną względem domyślnego katalogu i schematu pipeline'u

44. Co robi ta deklaracja w Lakeflow?

```
CONSTRAINT valid_id EXPECT (id IS NOT NULL) ON VIOLATION DROP ROW
```

- A. Zapisuje ostrzeżenie dla pustych identyfikatorów, ale zachowuje wszystkie wiersze
- B. Przerywa całe uruchomienie pipeline'u, jeśli znajdzie choć jeden pusty identyfikator
- C. Usuwa z tabeli docelowej wiersze, w których id ma wartość NULL, i uwzględnia je w metrykach jakości danych
- D. Zastępuje puste identyfikatory wartością domyślną

45. Co się dzieje, gdy expectation w Lakeflow używa ON VIOLATION FAIL UPDATE?

- A. Błędne wiersze są odrzucane, a pipeline działa dalej
- B. Błędne wiersze trafiają do kwarantanny w tabeli błędów
- C. Zapisywane jest ostrzeżenie, ale przetwarzanie trwa dalej
- D. Aktualizacja pipeline'u natychmiast kończy się błędem i dla tej tabeli nie zostają zapisane żadne dane

46. Co się dzieje, gdy expectation zadeklarowano bez klauzuli ON VIOLATION?

```
CONSTRAINT positive_amount EXPECT (amount > 0)
```

- A. Błędne wiersze są odrzucane
- B. Pipeline kończy się błędem
- C. Wszystkie wiersze są zachowane; zapisywane jest ostrzeżenie i rejestrowane są metryki
- D. Błąd — klauzula ON VIOLATION jest wymagana

47. Która składnia SQL w Lakeflow odczytuje nadrzędną streaming table z tego samego pipeline'u przyrostowo, jako źródło strumieniowe?

- A. `SELECT * FROM bronze_orders`
- B. `SELECT * FROM STREAM(bronze_orders)`
- C. `SELECT * FROM STREAMING(bronze_orders)`
- D. `SELECT * FROM READ_STREAM(bronze_orders)`

48. Gdzie można zobaczyć metryki jakości danych (liczby wierszy spełniających i niespełniających warunków) dla expectations w Lakeflow?

- A. `SHOW QUALITY METRICS FOR silver_table`
- B. `DESCRIBE EXPECTATIONS silver_table`
- C. `SELECT * FROM INFORMATION_SCHEMA.EXPECTATIONS`
- D.

```
SELECT * FROM event_log(TABLE(catalog.schema.silver_table))
WHERE details:flow_progress:data_quality IS NOT NULL
```

49. Czym jest zadanie (task) w jobie Lakeflow Jobs (dawniej Workflows)?

- A. Osobną konfiguracją klastra
- B. Pojedynczą jednostką pracy (notebook, SQL, skrypt Python lub pipeline), którą job orkestruje
- C. Ustawieniem uprawnień
- D. Kanałem powiadomień

50. Co robi `dbutils.jobs.taskValues.set()`?

Task 1:

```
dbutils.jobs.taskValues.set(key="row_count", value=1000)
```

Task 2 (zależny):

```
count = dbutils.jobs.taskValues.get(taskKey="Task_1", key="row_count")
```

- A. Przekazuje wartość z jednego zadania do zadania zależnego w ramach tego samego uruchomienia joba
- B. Ustawia zmienną środowiskową na poziomie joba
- C. Konfiguruje parametry klastra
- D. Ustawia liczbę ponownych prób zadania

51. Czym jest „Repair Run” w Lakeflow Jobs?

- A. Pełnym ponownym uruchomieniem całego joba od zera
- B. Ponownym uruchomieniem tylko zadań zakończonych błędem (i zadań od nich zależnych) bez powtarzania zadań zakończonych sukcesem
- C. Ręczną poprawką konfiguracji joba
- D. Przywróceniem poprzedniej wersji joba

52. Jakiego typu zadań może orkestrować job w Lakeflow Jobs?

- A. Notebook, SQL, skrypt Python, pipeline Lakeflow, JAR
- B. Tylko notebooki
- C. Tylko SQL i Python
- D. Tylko pipeline'y Lakeflow

53. Która funkcja Unity Catalog jest dołączana bezpośrednio do tabeli, tak aby każde zapytanie do tej tabeli zwracało tylko wiersze, które użytkownik może zobaczyć?

- A. Column Mask
- B. Dynamic View
- C. Row Filter
- D. Data Profile

54. Jak zastosować Column Mask do tabeli w Unity Catalog?

- A. `GRANT MASK ON COLUMN email TO mask_func`
- B. `CREATE MASK ON TABLE t COLUMN email`
- C. `UPDATE TABLE t SET COLUMN email MASKED`
- D. `ALTER TABLE t ALTER COLUMN email SET MASK catalog.schema.mask_func`

55. Który widok INFORMATION_SCHEMA należy odpytać, aby wyświetlić wszystkie tabele i widoki w katalogu Unity Catalog?

- A. `INFORMATION_SCHEMA.SCHEMATA`
- B. `INFORMATION_SCHEMA.TABLES`
- C. `INFORMATION_SCHEMA.COLUMNS`
- D. `INFORMATION_SCHEMA.TABLE_PRIVILEGES`

56. Której funkcji SQL używa się w Row Filters i Column Masks, aby sprawdzić, czy użytkownik wykonujący zapytanie należy do określonej grupy?

- A. `is_account_group_member('admins')`
- B. `user_in_group('admins')`
- C. `has_role('admins')`
- D. `check_group('admins')`

57. Partnerzy wgrywają paczki plików CSV do wolumenu Unity Catalog w nieprzewidywalnych momentach, kilka razy dziennie. Job przetwarzający powinien startować wkrótce po każdej dostawie i nie uruchamiać się wcale, gdy nic nie przyszło. Który trigger powinien wybrać data engineer?

- A. Trigger harmonogramu uruchamiany co 5 minut
- B. Trigger continuous
- C. Trigger file arrival na ścieżce wolumenu
- D. Ręczne uruchomienie przez dyżurnego inżyniera

58. Które polecenie, zgodnie z zasadą najmniejszych uprawnień, daje grupie `analysts` dostęp do odczytu wszystkich tabel w schemacie `silver`?

- A. `GRANT SELECT ON SCHEMA my_catalog.silver TO analysts`
- B. `GRANT READ ON DATABASE silver TO analysts`
- C. `GRANT ALL PRIVILEGES ON SCHEMA my_catalog.silver TO analysts`
- D. `ALLOW SELECT ON my_catalog.silver FOR analysts`

59. Jak usunąć Row Filter z tabeli?

- A. `DROP FILTER ON TABLE t`
- B. `ALTER TABLE t DROP ROW FILTER`
- C. `REVOKE ROW FILTER FROM t`
- D. `DELETE ROW FILTER ON t`

60. Data engineer pracuje w Git folderze. Zdalna gałąź `main` jest chroniona i przyjmuje tylko zrecenzowane pull requesty. Musi zmienić notebook i doprowadzić do scalenia zmiany. Jaki jest poprawny sposób pracy?

- A. W oknie Git folderu utworzyć gałąź roboczą, zmienić notebook, wykonać commit i push do tej gałęzi, a następnie otworzyć pull request u dostawcy Git, aby scalić zmianę z `main`
- B. Wyeksportować notebook jako archiwum `.dbc` i wysłać je właścicielowi repozytorium
- C. Edytować notebook na `main` i wybrać **Commit & Push**; Databricks omija ochronę gałęzi
- D. Uruchomić `databricks bundle deploy -t prod`, aby scalić zmianę z `main`

61. Po tym, jak współpracownik zainstalował `pandas==1.5.3` jako bibliotekę klastra na współdzielonym klastrze `all-purpose`, notebooki działające jeszcze wczoraj kończą się błędem `AttributeError` w wywołaniach `pandas`. Kłaster uruchamia się normalnie, a metryki pamięci wyglądają prawidłowo. Jaka jest najbardziej prawdopodobna przyczyna i zalecane rozwiązanie?

- A. Brak pamięci na executorach (OOM); należy zwiększyć `spark.executor.memory`
- B. Błąd startu klastra; należy sprawdzić log init scriptu
- C. Skośność danych; należy włączyć obsługę skew join w AQE
- D. Konflikt bibliotek z wersją `pandas`, której oczekuje kod; należy usunąć bibliotekę klastra i przypiąć potrzebną wersję w notebooku przez `%pip install` (lub w środowisku `serverless`)

62. Zespół ma zewnętrzną tabelę Delta `sales.bronze.orders` zarejestrowaną w Unity Catalog. Chce, aby Unity Catalog zarządzał jej magazynem i cyklem życia (w tym `predictive optimization`), bez zmiany nazwy tabeli i bez utraty jej historii. Które polecenie to realizuje?

- A. `ALTER TABLE sales.bronze.orders SET TBLPROPERTIES ('managed' = 'true')`
- B. `ALTER TABLE sales.bronze.orders SET MANAGED`
- C. `CREATE TABLE sales.bronze.orders_managed DEEP CLONE sales.bronze.orders`
- D.

```
DROP TABLE sales.bronze.orders;  
CREATE TABLE sales.bronze.orders LOCATION 'abfss://landing@acct.dfs.core.windows.net/orders';
```

63. Nocny job, który zwykle trwa około 20 minut, przez cały tydzień kończył się sukcesem, ale dzisiejsze udane uruchomienie trwało 75 minut. Jak data engineer powinien potwierdzić, czy to regresja, i ustalić, gdzie zniknął dodatkowy czas?
- A. Zrestartować klaster i ponownie uruchomić joba; jeśli się powiedzie, analiza nie jest potrzebna
 - B. Uruchomić `DESCRIBE DETAIL` na tabeli docelowej joba
 - C. Otworzyć historię uruchomień joba i porównać dzisiejszy czas z poprzednimi uruchomieniami, a w widoku macierzy (matrix view) sprawdzić, czas którego zadania wzrósł względem typowych wartości
 - D. Przeczytać dzisiejsze wyniki notebooka; czasy wcześniejszych uruchomień nie są przechowywane
64. Data engineer musi pobierać dane z Salesforce do tabel Delta objętych nadzorem Unity Catalog, z minimalną ilością własnego kodu i zarządzaną obsługą CDC. Które podejście do ingestii powinien wybrać w pierwszej kolejności?
- A. Zarządzany konektor Lakeflow Connect
 - B. Auto Loader z `cloudFiles` na wyeksportowanych plikach CSV
 - C. Sterownik JDBC w notebooku uruchamianym przez Lakeflow Jobs
 - D. `COPY INTO` z obszaru przejściowego w magazynie chmurowym
65. Zespół ma jedną bazę kodu dla joba i pipeline'u Lakeflow, które trzeba promować między workspace'ami dev, test i prod z różnymi katalogami. Który mechanizm jest do tego przeznaczony?
- A. Klonowanie Git folderu do każdego workspace'u i ręczna edycja ścieżek notebooków
 - B. Jeden job z osobnym zadaniem dla każdego środowiska
 - C. Eksport definicji joba do JSON i ręczny import w każdym workspace
 - D. Targety Declarative Automation Bundles (dawniej Databricks Asset Bundles) z nadpisaniami zmiennych
66. W Spark UI na jednym etapie większość zadań kończy się w kilka sekund, a kilka zadań trwa wiele minut, przy czym ich shuffle read jest znacznie większy od mediany. Jaka jest najbardziej prawdopodobna przyczyna?
- A. Zrzut na dysk (disk spill) spowodowany zbyt dużą pamięcią executorów
 - B. Konflikt bibliotek na klastrze
 - C. Skośność danych — kilka partycji zawiera nieproporcjonalnie dużo rekordów dla niektórych kluczy
 - D. Za mało kolumn wybranych w zapytaniu
67. Organizacja chce centralnie maskować KAŻDĄ kolumnę tabeli oznaczoną tagiem `pii = email`, bez dodawania maski do każdej tabeli z osobna. Która funkcja Unity Catalog to umożliwia?
- A. Polityki ABAC oparte na governed tags
 - B. Uprawnienia `DENY` na wybranych kolumnach
 - C. Dynamiczne widoki z `is_account_group_member()`
 - D. Ograniczenia odbiorców Delta Sharing
68. Jaki jest, zgodnie z aktualnymi zaleceniami Databricks, domyślny sposób utrzymywania dobrego klastrowania i kompaktowania zarządzanej tabeli Delta w Unity Catalog?
- A. Nocny job uruchamiający `OPTIMIZE ... ZORDER BY` i cotygodniowy `VACUUM`
 - B. Ręczne repartycjonowanie przez `df.repartition()` przed każdym zapisem
 - C. Statyczne partycjonowanie w stylu Hive według kolumny daty
 - D. Predictive optimization z (automatycznym) Liquid Clustering, np. `CLUSTER BY AUTO`

Klucz odpowiedzi

Dzień	Odpowiedzi
Dzień 1	1 C, 2 A, 3 C, 4 D, 5 C, 6 A, 7 B, 8 A, 9 B, 10 A
Dzień 1	11 D, 12 C, 13 D, 14 B, 15 D, 16 B, 17 D, 18 A, 19 C, 20 B
Dzień 2	21 A, 22 C, 23 B, 24 C, 25 A, 26 B, 27 C, 28 B, 29 D, 30 C
Dzień 2	31 A, 32 D, 33 B, 34 D, 35 A, 36 B, 37 D, 38 C, 39 A, 40 D
Dzień 3	41 C, 42 B, 43 D, 44 C, 45 D, 46 C, 47 B, 48 D, 49 B, 50 A
Dzień 3	51 B, 52 A, 53 C, 54 D, 55 B, 56 A, 57 C, 58 A, 59 B, 60 A
Dzień 3	61 D, 62 B, 63 C, 64 A, 65 D, 66 C, 67 A, 68 D

Pytania odzwierciedlają stan platformy na wrzesień 2026 r. oraz exam guide egzaminu Databricks Certified Data Engineer Associate z maja 2026 r. Nazwy produktów są zgodne z aktualną terminologią Databricks: Lakeflow Jobs (dawniej Workflows), Lakeflow Spark Declarative Pipelines (dawniej Delta Live Tables) oraz Declarative Automation Bundles (dawniej Databricks Asset Bundles). Te same pytania, z wyjaśnieniem każdej odpowiedzi, znajdują się w notebookach szkoleniowych `utilization/quiz/day1_quiz.ipynb`, `day2_quiz.ipynb` i `day3_quiz.ipynb`.